



RAG Pilot 全链路体验指南

10

分钟验证解析、OCR、切片、召回、引用、Trace、评测、安全隔离、Agent 实验与配置发布回滚。

RAGOPS CONTROLLED DEMO

DEMO GUIDE

01 · 演示地图

建议按页码顺序体验，所有账号与数据均为虚构。

角色入口

`demo_owner`：组织治理、发布与回滚
`demo_km`：文档、解析、索引、评测与 Agent
`demo_auditor`：只读 Trace、评测与授权审计
`demo_engineer`：全员、研发与本人薪资资料
`demo_hr`：HR 与薪酬资料
`demo_vendor`：另一租户，仅供应商资料

目标

面试官可以亲手验证同一问题在不同身份下得到不同的授权召回范围。

02 · 文档解析

上传后由 Celery 异步执行文件校验与统一 IR 解析。

统一 IR

Document IR → Page IR → Block IR。Block 保存 page、heading_path、bbox、paragraph 和 parser metadata。

质量门禁

观察文本覆盖率、空白页比例、异常字符率、OCR 页比例与解析耗时。低质量结果需人工确认。

03 · OCR 验证

《混合扫描应急预案》第 3 页是纯图片页。

操作

在解析预览切换到第 3 页，确认 `extraction_method=ocr`，并搜索灾备验证码 ORION-7421。

边界

本地文本页不会发送外部 OCR，只有扫描候选页组成子 PDF 提交 PaddleOCR。

04 · 切片与索引

选择 `Sentence` 或 `Markdown Chunker`，观察来源位置保持。

来源链

`Chunk metadata` 保存

`page_numbers`、`heading_path`、`block_ids`、`paragraph_range` 与 `parse_run_id`。

索引签名

文件、解析器、`Chunker`、`Embedding` 模型、维度、`Vector backend` 与 `schema` 共同生成签名。

0 5 · 召回与引用

0 5 · 召回与引用

问题：P 0 故障触发后，多久必须完成升级通知？

预期

回答包含“5 分钟内”，并引用《研发故障响应与发布流程》第 2 页。

可观测

在 Debug 查看

Vector、BM25、Hybrid / RRF、Rerank、Compression 的候选变化。

06 · Trace 复盘

06 · Trace 复盘

打开刚才问答的 `Trace`。

检查项

`Query Router`、`Rewrite`、阶段分数、位置、`Token`、延迟、配置版本和权限
`Scope fingerprint`。

隐私

`Trace` 不保存完整 `Prompt` 或 `Context`，只保留必要 `ID`、`Hash` 与脱敏摘要。

07 · 四类评测

运行 `smoke`、`benchmark`、`regression`、`release` 与 `security`。

Deterministic

`router_intent`、`answer_contains`、`citation_required`、`vector_hit`、`rerank_keep`、`max_latency_ms`。

Judge

固定 Prompt + JSON Schema 输出

`correctness_score`、`citation_score`、`hallucination_risk` 和 `reason`。

08 · 权限安全

分别使用 `demo_engineer` 与 `demo_hr` 查询“管理层奖金系数”。

工程师

`Vector`、`BM25`、`Hybrid`、`Rerank`、`Compression` 均不得出现薪酬 `Chunk`。

HR

满足 `clearance` 与 `Role` 授权后可召回薪酬制度；跨 `Organization` 仍为零。

09 · Agent 实验

选择预置 `Baseline`，点击开始诊断与优化。

闭环

Agent 定位 `recall/rerank` 失败 → 生成 `Variant` → HITL 确认
→ `Celery` 评测 → 选择 `Winner`。

稳定门禁

`Winner` 必须提升至少 `0.01`、失败 `Case`
不增加、`Deterministic/Judge` 通过且性能劣化不超过 `20%`。

1 0 · 发布与回滚

1 0 · 发布与回滚

Release Suite 通过后才出现发布 Action Card。

发布

确认后原子切换 `KnowledgeBase.active_config_version`，并记录 `RagConfigDeployment`。

回滚

选择历史上已发布且验证通过的版本，创建独立 `HITL` 卡并记录原因。